

Longboard Trick Tanımlama — Genel Değerlendirme

1. Ne Yaptık ve Amaç Neydi?

Elimizde her biri yaklaşık 12 saniyelik ~1500+ etiketli video var. Her video bir klasörde, klasör adı o videonun trick adına karşılık geliyor. Örneğin Caveman/ klasöründeki tüm videolar Caveman tricki içeriyor.

Veri hazırlama adımları:

- Her video kare kare açıldı
- Her karede **YOLOv8** ile kişinin 17 eklem noktası (omuz, diz, ayak bileği vb.) tespit edildi
- Bu koordinatlar normalize edildi — kişinin kameraya uzaklığı ve boyu fark etmesin diye
- Her 30 ardışık kare birleştirilerek bir "örnek" (sliding window) oluşturuldu
- Tüm örnekler X.npy dosyasına, etiketler y.npy 'ye kaydedildi
- BiLSTM modeli bu verilerle eğitildi

Amaç: Modelin "bu 30 karelik hareket dizisi hangi trick?" sorusunu cevaplamasını öğrenmesi.

YOLOv8 Nedir? YOLOv8, Ultralytics tarafından geliştirilen gerçek zamanlı nesne tespiti ve poz tahmini modelidir. "You Only Look Once" (yalnızca bir kez bak) prensibine dayanır — görüntüyü tek bir geçişte analiz ederek hem kişiyi hem de vücuttaki eklem noktalarını milisaniyeler içinde tespit eder. Bu projede yolo8s-pose modeli kullanılmıştır: her karede kişi başına COCO iskelet standardına göre 17 eklem noktası (burun, omuzlar, dirsekler, bilekler, kalçalar, dizler, ayak bilekleri) koordinat ve güven skoru olarak çıkarılmaktadır.

2. Neden BiLSTM Seçildi?

Trick tanımlama özünde bir **zaman serisi problemi**dir. Bir trick tek bir kareyle tanımlanamaz — örneğin Caveman'de kişi önce tahtayı eline alır, sonra havaya atlar, sonra iner. Bu sıra önemlidir.

BiLSTM (Bidirectional Long Short-Term Memory) hem ileriye hem geriye doğru zamansal bağlantıları öğrenebildiği için bu tür ardışık hareketleri modellemek için uygundur.

Diğer yaklaşımlar neden uygun değil?

Model	Neden elendi
Tek kare CNN	Sadece o anki pozı görür, hareketin akışını göremez. "Havada duran kişi" her trick'te aynı görünür.
Random Forest / SVM	30×51 boyutlu zaman serisini düzleştirip beslediğinde zamansal sıra bilgisi tamamen kaybolur.
Transformer	Teorik olarak daha güçlü ama ~20.000 örneklik veri setinde aşırı parametre sayısı nedeniyle ezber yapma (overfitting) riski yüksektir ve eğitim süresi çok uzar.
Tek yönlü LSTM	Sadece geçmişe bakar. Oysa bazı trick'lerde önceki hareket, sonraki hareketi anlamlandırır — BiLSTM her iki yönü de kullandığı için daha yüksek doğruluk sağlar.

Az veri, kısa sekans ve yorumlanabilirlik gereksinimi göz önünde bulundurulduğunda BiLSTM bu problem için pratik optimum seçimdir.

3. Mevcut Modelin Zayıf Noktası

12 saniyelik videonun içinde gerçek trick hareketi sadece **1-2 saniye** sürüyor. Geri kalan 10 saniye şunları içeriyor:

- Kişi longboarda yürüyerek biniyor
- Pozisyon alıyor
- Trick bittikten sonra duraksıyor
- Kamera hâlâ çekiyor

Sayısal olarak:

	Değer
12 sn × 15fps (her 2. kare)	~180 kare
30 karelik pencere, 15 stride → pencere sayısı	~10 pencere / video
Gerçek trick içeren pencere	1-2 pencere
"Düz yürüyüş / bekleme" içeren ama trick etiketi taşıyan pencere	8-9 pencere

Modele gösterilen örneklerin **%80'i aslında o trick değil** — ama etiket öyle yazıyor. Model "Caveman nedir?" yerine "Caveman videosunda kişi nasıl yürür?" öğreniyor.

Bu kritik bir sorundur çünkü tüm trick'lerdeki "düz yürüyüş" birbirine çok benziyor. Model sınıflar arasındaki gerçek hareketi öğrenmek yerine bu gürültüyü ezberliyor.

Mevcut test sonuçları:

Sınıf	Precision	Neden?
Caveman	%92	436 video → en çok veri, model ezber yapabiliyor
Ghostride	%31	Az veri + video içinde "sürüş" görüntüsü fazla
NollieFrontside180Shuvit	%21	20 video × 8 gürültülü pencere = model hiç öğrenemiyor

Genel test doğruluğu: %57

4. Videolar Kırılırsa Ne Değişir?

Her videonun sadece gerçek trick'in olduğu kısmı (örneğin 4-6. saniyeler) işlenirse:

- Her video için ~10 pencere yerine **2-3 temiz pencere** kalır
- Bu pencerelerin **tamamı gerçek trick hareketi** içerir
- Model artık "Caveman'da kişi şu şekilde havaya kalkar" öğrenir, "Caveman videosunda kişi düz yürür" değil
- Sınıflar arasındaki "düz yürüyüş" gürültüsü büyük ölçüde ortadan kalkar

Beklenen sonuç (tahmini):

	Mevcut	Kırma Sonrası
Test doğruluğu	%57	%68–78
Macro F1	%49	%60–70
NollieFrontside180 gibi zayıf sınıflar	%21–23	%40–55

Kesin rakam kırma kalitesine bağlıdır — doğru kırılırsa üst değerlere yaklaşılr.

5. Sistem 1 Dakikalık Videoda Trick'i Bulabilir mi?

Evet. main.py ve viewer.py **sliding window** mantığıyla çalışır:

- Her kare işlenir, son 30 kare sürekli bir tamponda tutulur
- Tampon dolduğunda model çalışır → "Bu 30 kare hangi trick?" sorusunu cevaplar
- 1 dakikalık videoda model yaklaşık **900 kez** tahmin yapar

Ancak mevcut modelle şu sorun ortaya çıkar: videonun 58 saniyesi "düz sürüş" olduğundan model bu anlarda da bir şeyler "tahmin etmeye" çalışır ve yanlış pozitif üretir.

Bu iki mekanizma ile kısmen engellenir:

- TRICK_FLASH_CONF_MIN = 0.50 — model %50'nin altında güvende ise ekranda göstermez
- PRED_VOTE_BUF_LEN = 60 — 60 ardışık karenin çoğunluğu aynı trick'i söylüyorsa göster

Kırılmış veriyle eğitilmiş model bu problemi kökten azaltır: model "trick nasıl görünür" öğrendiği için, trick olmayan anlarda güveni düşük kalır ve eşiği geçemez.

Durum	Mevcut Model	Kırılmış Veriyle Eğitilmiş Model
Düz sürüş anında tahmin	Sık yanlış pozitif	Düşük güven → sessiz kalır
Trick anında tahmin	%57 doğruluk	%68–78 doğruluk (tahmini)
Yanlış trick söyleme	Sık	Nadir

Özet

Mevcut yaklaşımda eğitim verisi, videonun tamamından elde edilen sliding window örneklerinden oluşmaktadır. Ancak etiketlenen hareket (trick), videonun yalnızca küçük bir bölümünde gerçekleşmektedir. Bu durum, eğitim örneklerinin büyük çoğunluğunun gürültüden ibaret olmasına ve modelin sınıflar arası gerçek farkları öğrenmekte zorlanmasına yol açmaktadır.

Trick segmentlerinin doğru şekilde belirlenerek yalnızca bu segmentler üzerinde eğitim yapılması, hem sınıflandırma doğruluğunu hem de gerçek zamanlı kullanımda yanlış pozitif oranını anlamlı ölçüde iyileştirmesi beklenmektedir.